

Tarea 03: Generación de imágenes con autoencoder PyTorch Lightning – Hydra – WandB

Fabrizio Mena Mejía

Instituto Tecnológico de Costa Rica

Email: fabriciomena11@estudiantec.cr

Anthony Fuentes Calvo

Instituto Tecnológico de Costa Rica

Email: anthonyfuentescalvo@estudiantec.cr

Fernando Sánchez Hidalgo

Instituto Tecnológico de Costa Rica

Email: Fer.sanchez@estudiantec.cr

Abstract—Este documento describe el desarrollo de la Tarea 03 del curso de Inteligencia Artificial: la implementación y evaluación de modelos generativos basados en autoencoders para la reconstrucción de imágenes industriales. Siguiendo el enunciado, se experimentan dos arquitecturas—un Variational Autoencoder (VAE) y un autoencoder tipo U-Net con conexiones salto—sobre el dataset MVTec AD, restringido a las clases *cable*, *capsule*, *screw* y *transistor*, con imágenes de entrada de 128×128 píxeles y tres canales. El entrenamiento se estructura con PyTorch Lightning, la gestión modular de hiperparámetros con Hydra y el registro comparativo de experimentos en Weights & Biases. Para cada arquitectura se prevén al menos cuatro corridas que difieren en la función de pérdida (L1, L2, SSIM y SSIM+L1), con el fin de analizar reconstrucciones en validación y prueba, el comportamiento del espacio latente (t-SNE) y la separabilidad del error de reconstrucción entre muestras normales y anómalas.

Index Terms—Autoencoder, variational autoencoder, U-Net, detección de anomalías, MVTec AD, PyTorch Lightning, Hydra, Weights & Biases, reconstrucción de imágenes.

I. INTRODUCCIÓN

La detección de defectos en entornos industriales puede abordarse de forma no supervisada aprendiendo a reconstruir únicamente patrones normales de producto o textura. Cuando un autoencoder se entrena con imágenes sin anomalías, las reconstrucciones tienden a ser fieles en casos normales y a degradarse ante defectos no vistos, lo que convierte el error de reconstrucción en una señal útil para la detección.

La Tarea 03 del curso de Inteligencia Artificial solicita implementar y comparar dos familias de modelos—VAE y U-Net—sobre el benchmark MVTec AD, utilizando un subconjunto de cuatro clases y resolución fija de 128×128 . El flujo experimental debe ser reproducible mediante configuraciones Hydra, el ciclo de entrenamiento debe organizarse con PyTorch Lightning, y los resultados (pérdidas, reconstrucciones y visualizaciones del espacio latente) deben centralizarse en WandB para su comparación sistemática entre funciones de pérdida.

Este informe acompaña el notebook de la tarea y documentará, en secciones posteriores, el dataset y preprocesamiento, el diseño de arquitecturas, los experimentos de entrenamiento y el análisis crítico de reconstrucciones en imágenes normales y defectuosas.